

Modelos Generativos I

Machine Learning 2 2026.1


Francisco Ganacim, Daniel Yukimura

IMPA

April 27, 2026

Aprendizado Supervisionado vs Não Supervisionado I


- ▶ Supervisionado: Aprendizado a partir de dados com rótulos
 - ▶ Dados: $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$
 - ▶ Objetivo: aprender $y_i = f(x_i) = f(x_i; \theta)$
 - ▶ Exemplos: classificação, regressão, detecção de objetos, **segmentação semântica**



Aprendizado Supervisionado vs Não Supervisionado

- ▶ Criar um *dataset* rotulado é trabalhoso:
- ▶ Requer dados anotados por humanos

the black dog is waiting to play frisbee.
a dog that is standing up with a frisbee.
a dog is gripping the frisbee while approaching.
a large black dog walking across a gravel field with an orange frisbee in it's mouth.
a dog running with a frisbee in it's mouth.




Aprendizado Supervisionado vs Não Supervisionado

- ▶ Aprendizado não supervisionado: somente dados sem rótulos
- ▶ Dados: $\mathcal{D} = \{x_1, \dots, x_N\}$
- ▶ Objetivo: aprender a estrutura dos dados
- ▶ Não requer rótulos anotados por humanos

Aprendizado Supervisionado vs Não Supervisionado


► Exemplo: Clusterização

K-means clustering on the digits dataset (PCA-reduced data)
Centroids are marked with white cross



Aprendizado Supervisionado vs Não Supervisionado

► Exemplo: Redução de Dimensionalidade: PCA




[7] 2025 — sklearn — *A demo of K-Means clustering on the handwritten digits data*

[4] 2025 — mathias scholz mathias — *PCA - Principal Component Analysis*

Aprendizado Supervisionado vs Não Supervisionado


- ▶ Exemplo: Estimação de Densidade: Gaussian Mixture Model



[7] 2025 ·
[4] 2025 ·
[8] 2025 ·
[9] 2024 ·

Aprendizado Supervisionado vs Não Supervisionado

► Exemplo: Aprendizado de Representação: Autoencoders



[7] 2025 — sklearn — *A demo of K-Means clustering on the handwritten digits data*

[4] 2025 — mathias scholz mathias — *PCA - Principal Component Analysis*

[8] 2025 — sklearn — *Comparison of Manifold Learning methods*

[9] 2024 — Wikipedia — *Multivariate kernel density estimation*

Modelos Discriminativos e Generativos

- ▶ Discriminativo
 - ▶ Aprende a distribuição $P(y|x)$
- ▶ Generativo
 - ▶ Aprende a distribuição $P(x)$
- ▶ Generativo Condicional
 - ▶ Aprende a distribuição $P(x|y)$

Modelos Discriminativos e Generativos

- ▶ Discriminativo
 - ▶ Aprende a distribuição $P(y|x)$



$$P(y = \text{"cat"} | \cdot) = 0.87$$
$$P(y = \text{"dog"} | \cdot) = 0.13$$



$$P(y = \text{"cat"} | \cdot) = 0.2$$
$$P(y = \text{"dog"} | \cdot) = 0.8$$

Modelos Discriminativos e Generativos


- ▶ Discriminativo
 - ▶ Aprende a distribuição $P(y|x)$



$$P(y = \text{"cat"} | \cdot) = 0.4$$

$$P(y = \text{"dog"} | \cdot) = \text{0.6}$$

- ▶ O modelo não é capaz de rejeitar x fora da distribuição em que foi treinado



$$P(y = \text{"cat"} | \cdot) = 0.01$$

$$P(y = \text{"dog"} | \cdot) = \text{0.99}$$

Modelos Discriminativos e Generativos

► Generativo

- Aprende a distribuição $P(x)$
- Deve atribuir valores altos para x na distribuição e baixos para x fora da distribuição onde foi treinado
- $\int P(x)dx = 1$

Modelos Discriminativos e Generativos


- ▶ Generativo Condicional
 - ▶ Aprende a distribuição $P(x|y)$

Modelos Discriminativos e Generativos

- ▶ Generativo Condicional
 - ▶ Aprende a distribuição $P(x|y)$



$$P(.|y = \text{"dog"}) = 0.9$$
$$P(.|y = \text{"cat"}) = 0.01$$



$$P(.|y = \text{"dog"}) = 0.2$$
$$P(.|y = \text{"cat"}) = 0.85$$



$$P(.|y = \text{"dog"}) = 0.15$$
$$P(.|y = \text{"cat"}) = 0.2$$


Modelos Discriminativos e Generativos

▶ Generativo Condicional

- ▶ Aprende a distribuição $P(x|y)$
- ▶ Pode ser usado para categorizar X avaliando para todos os y



$$P(\cdot | y = \text{"dog"}) = 0.9$$
$$P(\cdot | y = \text{"cat"}) = 0.01$$



$$P(\cdot | y = \text{"dog"}) = 0.2$$
$$P(\cdot | y = \text{"cat"}) = 0.85$$



$$P(\cdot | y = \text{"dog"}) = 0.15$$
$$P(\cdot | y = \text{"cat"}) = 0.2$$

Modelos Discriminativos e Generativos

- ▶ Mas eles são todos relacionados...

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

- ▶ $P(y)$ é o prior de y (labels)
- ▶ $P(x)$ é o modelo generativo ou prior de x
- ▶ $P(y|x)$ é o modelo discriminativo

Modelos Discriminativos e Generativos

- ▶ Mas eles são todos relacionados...

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$
$$\implies \log(P(x|y)) = \log(P(y|x)) + \log(P(x)) - \log(P(y))$$

Modelos Discriminativos e Generativos


- ▶ Mas eles são todos relacionados...

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$
$$\implies \log(P(x|y)) = \log(P(y|x)) + \log(P(x)) - \log(P(y))$$


Voltando algumas aulas nós tínhamos...

Modelos Discriminativos e Generativos

$$\hat{I} = \arg \max_I S_c(I) + \lambda R(I)$$




Goose




Scorpion

Modelos Discriminativos e Generativos

$$\begin{aligned}\hat{I} &= \arg \max_I S_c(I) + \lambda R(I) \\ &= \arg \max_I \log P(y = C|I) + \lambda \log P(I)\end{aligned}$$



Goose



Scorpion

Podemos usar os modelos para...

- ▶ Discriminativo:
 - ▶ Classificação
 - ▶ Feature learning supervisionado

Podemos usar os modelos para...


- ▶ Discriminativo:
 - ▶ Classificação
 - ▶ Feature learning supervisionado
- ▶ Generativos:
 - ▶ Detecção de outliers
 - ▶ Geração de dados sintéticos
 - ▶ Feature learning sem rótulos

Podemos usar os modelos para...

- ▶ Discriminativo:
 - ▶ Classificação
 - ▶ Feature learning supervisionado
- ▶ Generativos:
 - ▶ Detecção de outliers
 - ▶ Geração de dados sintéticos
 - ▶ Feature learning sem rótulos
- ▶ Generativo condicional
 - ▶ rotulagem e rejeição de outliers
 - ▶ geração de dados sintéticos condicionadas

Alguns tipos de modelos generativos

- ▶ Explícitos: computam $p(x)$ diretamente
 - ▶ Modelos Autoregressivos
 - ▶ Variational Autoencoders (VAEs)
 - ▶ Modelos de Difusão
- ▶ Implícitos: não computam $p(x)$ diretamente, mas podem ser amostrados
 - ▶ GANs



[6] 2023 — Simon Prince — *Understanding Deep Learning*

[1] 2017 — Ian Goodfellow — *NIPS 2016 Tutorial: Generative Adversarial Networks*

Modelos Autoregressivos

- ▶ Queremos modelar $P(x) = f(x, \theta)$ explicitamente
- ▶ Dado o dataset

$$X = \{x^{(1)}, x^{(2)}, \dots, x^{(n)}\}$$

- ▶ Treinamos o modelo usando a MLE

$$\begin{aligned}\hat{\theta} &= \arg \max_{\theta} \prod_{i=1}^n p(x^{(i)}) \\ &= \arg \max_{\theta} \sum_{i=1}^n \log p(x^{(i)}) \\ &= \arg \max_{\theta} \sum_{i=1}^n \log f(x^{(i)}, \theta)\end{aligned}$$

Modelos Autoregressivos

- ▶ Porém usamos a estrutura dos dados para modelar $p(x)$
- ▶ Como

$$x = (x_1, x_2, \dots, x_T)$$

- ▶ Podemos escrever $P(x)$ como

$$\begin{aligned} P(x) &= P(x_1, x_2, \dots, x_T) \\ &= P(x_1)P(x_2|x_1)P(x_3|x_1, x_2) \dots P(x_T|x_1, x_2, \dots, x_{T-1}) \\ &= P(x) = \prod_{t=1}^T P(x_t|x_1, x_2, \dots, x_{t-1}) \end{aligned}$$


Modelos Autoregressivos: exemplos

► Language Models e RNNs

$$x_2 \sim P(x_2|x_1)$$

$$x_3 \sim P(x_3|x_2, x_1)$$

$$x_4 \sim P(x_4|x_3, x_2, x_1)$$



Modelos Autoregressivos: exemplos

► Language Models e RNNs

$P(\text{O rato roeu a roupa do rei de Roma}) =$

$P(\text{O})$

$P(\text{rato}|\text{O})$

$P(\text{roeu}|\text{O rato})$

$P(\text{a}|\text{O rato roeu})$

$P(\text{roupa}|\text{O rato roeu a})$

$P(\text{do}|\text{O rato roeu a roupa})$


$P(\text{rei}|\text{O rato roeu a roupa do})$

$P(\text{de}|\text{O rato roeu a roupa do rei})$


$P(\text{Roma}|\text{O rato roeu a roupa do rei de})$

Modelos Autoregressivos: exemplos


► Pixel RNN



Context



Multi-scale context




Próximos passos...

- ▶ VAEs: Variational autoencoders
- ▶ GANs: Generative adversarial networks
- ▶ Difusão

Mas antes....

Autoencoders




- ▶ Não supervisionado: extrai features a partir de dados não rotulados
- ▶ Por que não tomamos $z = Id(x)$ e $x' = Id(z)$?
- ▶ $\ell(x, x') = \|x - dec(enc(x))\|^2$ ou $\ell(x, x') = BCE(x, dec(enc(x)))$
- ▶ Geralmente convolucional para imagens.

Autoencoders: Aplicações

- ▶ Pré-treino para outras tarefas: como classificação de imagens, image captioning, entre outras
- ▶ Redução de dimensionalidade não linear: visualização, compressão, clusterização
- ▶ Denoising: remover ruído em dados


Tipos de Autoencoders

► Vanilla Autoencoder




Tipos de Autoencoders

► Vanilla Autoencoder



Tipos de Autoencoders


► Vanilla Autoencoder




Tipos de Autoencoders

► Vanilla Autoencoder

5




6




Regularização de Autoencoders

- Denoising Autoencoder: adiciona ruído aos dados de entrada



Regularização de Autoencoders

- Denoising Autoencoder: adiciona ruído aos dados de entrada




com ruído

goodfellow`deep`2016

Regularização de Autoencoders

- Denoising Autoencoder: adiciona ruído aos dados de entrada



sem ruído

goodfellow`deep`2016

Regularização de Autoencoders

- ▶ Denoising Autoencoder: adiciona ruído aos dados de entrada
- ▶ Sparse Autoencoder: força a representação latente a ser esparsa

Regularização de Autoencoders

- ▶ Denoising Autoencoder: adiciona ruído aos dados de entrada
- ▶ Sparse Autoencoder: força a representação latente a ser esparsa
- ▶ Contractive Autoencoder: força a representação latente a ser robusta a pequenas perturbações

Variantes importantes

- ▶ Convolutional Autoencoder: usa convoluções para aprender representações de imagens
- ▶ Adversarial Autoencoder: usa GANs para treinar o autoencoder
- ▶ Unets
- ▶ Variational Autoencoder: aprende uma distribuição sobre a representação latente z

Autoencoders I

- ▶ Unsupervisionado, extrai feature a partir de dados não rotulados
- ▶ Mostrar diagrama: encoder e decoder
- ▶ Podemos usar a representação latente para outras tarefas como Classificação
- ▶ $z = \text{encoder}(x)$ mas z não é conhecido
- ▶ $x' = \text{decoder}(z)$
- ▶ $L(x, x') = \|x - x'\|^2$
- ▶ $L(x, x') = \|x - \text{decoder}(\text{encoder}(x))\|^2$
- ▶ imagem de autoencoder
- ▶ EXEMPLO de autoencoder basico
- ▶ Não queremos aprender a identidade, queremos aprender a estrutura dos dados
- ▶ z deve ser menor que x (dimensionalidade reduzida) para aprender algo útil
- ▶ arquitetura é geralmente convolucional para imagens
- ▶ não é probabilístico: não há como fazer sampling de novas amostras?

Referências I

- [1] Ian Goodfellow. *NIPS 2016 Tutorial: Generative Adversarial Networks*. arXiv:1701.00160 [cs]. Apr. 2017. DOI: 10.48550/arXiv.1701.00160. URL: <http://arxiv.org/abs/1701.00160> (visited on 04/21/2025).
- [2] Lhocm. *Cute Banana Dog*. 2025. URL: <https://www.amazon.com.br/Figurines-Ornaments-Creative-Decorations-Personalized/dp/B09Y34YX6Q> (visited on 04/26/2025).
- [3] Tsung-Yi Lin et al. *Microsoft COCO: Common Objects in Context*. en. May 2014. URL: <https://arxiv.org/abs/1405.0312v3> (visited on 04/26/2025).
- [4] mathias scholz mathias. *PCA - Principal Component Analysis*. 2025. URL: http://www.nlpca.org/pca_principal_component_analysis.html (visited on 04/26/2025).

Referências II

- [5] Aaron van den Oord, Nal Kalchbrenner, and Koray Kavukcuoglu. *Pixel Recurrent Neural Networks*. arXiv:1601.06759 [cs]. Aug. 2016. DOI: 10.48550/arXiv.1601.06759. URL: <http://arxiv.org/abs/1601.06759> (visited on 04/25/2025).
- [6] Simon Prince. *Understanding Deep Learning*. 2023. URL: <https://udlbook.github.io/udlbook/> (visited on 12/20/2023).
- [7] sklearn. *A demo of K-Means clustering on the handwritten digits data*. en. 2025. URL: https://scikit-learn/stable/auto_examples/cluster/plot_kmeans_digits.html (visited on 04/26/2025).
- [8] sklearn. *Comparison of Manifold Learning methods*. en. 2025. URL: https://scikit-learn/stable/auto_examples/manifold/plot_compare_methods.html (visited on 04/28/2025).

Referências III

- [9] Wikipedia. “Multivariate kernel density estimation”. en. In: *Wikipedia* (Dec. 2024). Page Version ID: 1265478080. URL: https://en.wikipedia.org/w/index.php?title=Multivariate_kernel_density_estimation&oldid=1265478080 (visited on 04/28/2025).