

Modelos de Variável Latente

Machine Learning 2 2026.1

Francisco Ganacim, Daniel Yukimura

IMPA

May 4, 2026

Recapitulando

Modelos:

Recapitulando

Modelos:

- ▶ Discriminativos: $P(y|x)$
 - ▶ Discriminar entre classes.
 - ▶ Treinar features de forma supervisionada.

Recapitulando

Modelos:

- ▶ Discriminativos: $P(y|x)$
 - ▶ Discriminar entre classes.
 - ▶ Treinar features de forma supervisionada.
- ▶ Generativos: $P(x)$
 - ▶ Medir a verosimilhança de um dado x .
 - ▶ Gerar novas amostras.

Recapitulando

Modelos:

- ▶ Discriminativos: $P(y|x)$
 - ▶ Discriminar entre classes.
 - ▶ Treinar features de forma supervisionada.
- ▶ Generativos: $P(x)$
 - ▶ Medir a verosimilhança de um dado x .
 - ▶ Gerar novas amostras.
- ▶ Generativos condicional: $P(x|y)$
 - ▶ Gerar novas amostras condicionadas a uma classe.
 - ▶ Exemplo: $P(x|y = 1)$


Recapitulando

Modelos:

- ▶ Discriminativos: $P(y|x)$
 - ▶ Discriminar entre classes.
 - ▶ Treinar features de forma supervisionada.
- ▶ Generativos: $P(x)$
 - ▶ Medir a verosimilhança de um dado x .
 - ▶ Gerar novas amostras.
- ▶ Generativos condicional: $P(x|y)$
 - ▶ Gerar novas amostras condicionadas a uma classe.
 - ▶ Exemplo: $P(x|y = 1)$
- ▶ São relacionados por:

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

Apredizado não supervisionado: Autoencoders




- ▶ Não supervisionado: extrai features a partir de dados não rotulados
- ▶ $\ell(x, x') = \|x - \text{dec}(\text{enc}(x))\|^2$ ou $\ell(x, x') = BCE(x, \text{dec}(\text{enc}(x)))$
- ▶ Não é probabilístico.
- ▶ Usado como pré-treino para outros modelos.


Modelos generativos: problema

- ▶ Modelar $P(x)$ é complicado pois pode ser muito geral.
- ▶ É necessário dar alguma estrutura a $P(x)$.
- ▶ Uma forma de fazer isso é supor que $P(x)$ é uma combinação de distribuições mais simples, como gaussianas

Gaussian Mixture Model (GMM)



Gaussian Mixture Model (GMM)



Gaussian Mixture Model (GMM)

Vamos supor a existências de um conjunto $\mathcal{Z} = \{z_1, z_2, \dots, z_K\}$ de variáveis latentes que representam os componentes do modelo.

Dessa forma, podemos escrever a distribuição $P(x)$ como

$$P(x) = \sum_{k=1}^K P(x, z = k)$$

Onde $P(x, z)$ é a distribuição conjunta de x e z .

Portanto,

$$\begin{aligned} P(x) &= \sum_{k=1}^K P(x, z = k) \\ &= \sum_{k=1}^K P(z = k)P(x|z = k) \end{aligned}$$

Gaussian Mixture Model (GMM)

Tomando

- ▶ $P(z = k) = \pi_k$, com $\sum_{k=1}^K \pi_k = 1$ e $\pi_k \geq 0$, e
- ▶ $P(x|z = k) = \mathcal{N}(\mu_k, \sigma_k^2)$

Temos que

$$\begin{aligned} P(x) &= \sum_{k=1}^K P(z = k)P(x|z = k) \\ &= \sum_{k=1}^K \pi_k \mathcal{N}(\mu_k, \sigma_k^2) \end{aligned}$$

Como fitar esse modelo?

Poderíamos usar MLE: Assumindo que $\theta = \{\pi_1, \mu_1, \sigma_1^2, \cdot, \pi_k, \mu_k, \sigma_k^2\}$, são os parâmetros do modelo

$$\begin{aligned}\hat{\theta} &= \arg \max \prod_{i=1}^N P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\sum_{k=1}^K P(z = k|\theta) P(x_i|z = k, \theta) \right) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k \mathcal{N}(\mu_k, \sigma_k^2) \right)\end{aligned}$$

Sujeita a restrições: $\sum_{k=1}^K \pi_k = 1$, $\pi_k \geq 0$ e $\sigma_k^2 > 0$.

Como fitar esse modelo?

Poderíamos usar MLE: Assumindo que $\theta = \{\pi_1, \mu_1, \sigma_1^2, \cdot, \pi_k, \mu_k, \sigma_k^2\}$, são os parâmetros do modelo

$$\begin{aligned}\hat{\theta} &= \arg \max \prod_{i=1}^N P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k \mathcal{N}(\mu_k, \sigma_k^2) \right)\end{aligned}$$

Sujeita a restrições: $\sum_{k=1}^K \pi_k = 1$, $\pi_k \geq 0$ e $\sigma_k^2 > 0$.

Problemas:

- ▶ Gradiente é complicado devido a soma dentro do logaritmo
- ▶ É um problema com restrições
- ▶ Provavelmente instável numericamente

Expectation-Maximization (EM) I

Temos:

$$x_n \sim P(x) \quad \text{para } n = 1, \dots, N$$

1. **Inicialização:** Escolher parâmetros iniciais:

$$\theta^{(0)} = \{\mu_k^{(0)}, \sigma_k^{2(0)}, \pi_k^{(0)}\} \quad \text{para } k = 1, \dots, K$$

2. **E-step:** Computar as *responsabilidades*:


$$\gamma_{nk}^{(t)} = P(z = k | x_n, \theta^{(t)}) = \frac{P(z = k | \theta^{(t)}) P(x_n | z = k, \theta^{(t)})}{P(x_n | \theta^{(t)})} = \frac{\pi_k^{(t)} \mathcal{N}(x_n | \mu_k^{(t)}, \sigma_k^{2(t)})}{\sum_{j=1}^K \pi_j^{(t)} \mathcal{N}(x_n | \mu_j^{(t)}, \sigma_j^{2(t)})}$$

3. **M-step:** Atualizar os parâmetros:


$$\left. \begin{aligned} N_k^{(t)} &= \sum_{n=1}^N \gamma_{nk}^{(t)} \\ \mu_k^{(t+1)} &= \frac{1}{N_k^{(t)}} \sum_{n=1}^N \gamma_{nk}^{(t)} x_n \end{aligned} \right| \begin{aligned} \pi_k^{(t+1)} &= \frac{N_k^{(t)}}{N} \\ \sigma_k^{2(t+1)} &= \frac{1}{N_k^{(t)}} \sum_{n=1}^N \gamma_{nk}^{(t)} (x_n - \mu_k^{(t+1)})^2 \end{aligned}$$

4. **Convergence:** Pare caso $\log P(x | \theta^{(t+1)})$ convirja. Caso contrário, repita 2 e 3.


Expectation-Maximization (EM): Exemplo



Expectation-Maximization (EM): Exemplo



Expectation-Maximization (EM): Exemplo



Modelos de variável latente I

Como podemos generalizar o caso anterior para outros modelos?
Sabemos que, em geral:

$$\begin{aligned}P(x) &= \int P(x, z) dz \\ &= \int P(x|z)P(z) dz\end{aligned}$$

Portanto podemos escrever nosso modelo como

$$\begin{aligned}P(x|\theta) &= \int P(x, z|\theta) dz \\ &= \int P(x|z, \theta)P(z|\theta) dz\end{aligned}$$

Modelos de variável latente II

E tomamos

$$P(x|z, \theta) = \mathcal{N}_x(f(z, \theta), I * \sigma^2)$$

$$P(z|\theta) = \mathcal{N}_z(0, I)$$


Onde $f(z, \theta)$ é um modelo, em geral não linear, que mapeia a variável latente z para a variável observada x . E σ^2 é um hyperparâmetro.

Dessa forma, podemos escrever


$$\begin{aligned} P(x|\theta) &= \int P(x|z, \theta)P(z|\theta)dz \\ &= \int \mathcal{N}(f(z, \theta), I * \sigma^2)\mathcal{N}(0, I)dz \end{aligned}$$

Modelos de variável latente


Esta formulação permite modelar distribuições complexas




a) Prior, $Pr(z)$



b) Likelihood, $Pr(\mathbf{x} | z^*, \phi)$



c) Marginal, $Pr(\mathbf{x} | \phi)$



Modelos de variável latente

E também permite amostrar estas distribuições.

1. Amostre z de $P(z) = \mathcal{N}(0, I)$
2. Amostre x de $P(x|z, \theta) = \mathcal{N}(f(z, \theta), I * \sigma^2)$

Modelos de variável latente

E também permite amostrar estas distribuições.

1. Amostre z de $P(z) = \mathcal{N}(0, I)$
2. Amostre x de $P(x|z, \theta) = \mathcal{N}(f(z, \theta), I * \sigma^2)$

Porém calcular $P(x)$ ainda é um desafio por conta da integral.

$$\begin{aligned} P(x|\theta) &= \int P(x|z, \theta)P(z|\theta)dz \\ &= \int \mathcal{N}_x(f(z, \theta), I * \sigma^2)\mathcal{N}_z(0, I)dz \end{aligned}$$

Pois não há uma forma fechada para a integral.

Como podemos treinar o modelo?

Podemos tentar usar Expectation-Maximization (EM) para treinar o modelo.

No caso discreto tínhamos

1. ...

2. **E-step:** Computar as *responsabilidades*:

$$\gamma_{nk}^{(t)} = P(z = k | x_n, \theta^{(t)}) = \frac{P(z = k | \theta^{(t)})P(x_n | z = k)}{P(x_n | \theta^{(t)})}$$

Que é impossível de calcular, pois não temos uma forma fechada para $P(x|\theta)$.

Como podemos treinar o modelo?

Usando MLE, temos que maximizar o seguinte problema:

$$\begin{aligned}\hat{\theta} &= \arg \max \prod_{i=1}^N P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\int P(x_i|z, \theta) P(z|\theta) dz \right) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\int \mathcal{N}_x(f(z, \theta), I * \sigma^2) \mathcal{N}_z(0, I) dz \right)\end{aligned}$$

Como podemos treinar o modelo?

Usando MLE, temos que maximizar o seguinte problema:

$$\begin{aligned}\hat{\theta} &= \arg \max \prod_{i=1}^N P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\int P(x_i|z, \theta) P(z|\theta) dz \right) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\int \mathcal{N}_x(f(z, \theta), I * \sigma^2) \mathcal{N}_z(0, I) dz \right)\end{aligned}$$

Que é impossível de calcular, pois não temos uma forma fechada para $P(x|\theta)$!

Como podemos treinar o modelo?

Usando MLE, temos que maximizar o seguinte problema:

$$\begin{aligned}\hat{\theta} &= \arg \max \prod_{i=1}^N P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log P(x_i|\theta) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\int P(x_i|z, \theta) P(z|\theta) dz \right) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log \left(\int \mathcal{N}_x(f(z, \theta), I * \sigma^2) \mathcal{N}_z(0, I) dz \right)\end{aligned}$$

Que é impossível de calcular, pois não temos uma forma fechada para $P(x|\theta)$! Porém...

Como podemos treinar o modelo?

Podemos usar integração numérica: Monte Carlo.

$$\begin{aligned}P(x|\theta) &= \int P(x|z, \theta)P(z|\theta)dz \\&= \int P(x|z, \theta)\mathcal{N}_z(0, I)dz \\&= \mathbb{E}_{z \sim \mathcal{N}(0, I)}[P(x|z, \theta)] \\&\approx \frac{1}{M} \sum_{i=1}^M P(x|z_i, \theta), \quad z_i \sim \mathcal{N}(0, I)\end{aligned}$$



Como podemos treinar o modelo?

Podemos usar integração numérica: Monte Carlo.




$$\begin{aligned}P(x|\theta) &= \int P(x|z, \theta)P(z|\theta)dz \\&= \int P(x|z, \theta)\mathcal{N}_z(0, I)dz \\&= \mathbb{E}_{z \sim \mathcal{N}(0, I)}[P(x|z, \theta)] \\&\approx \frac{1}{M} \sum_{i=1}^M P(x|z_i, \theta), \quad z_i \sim \mathcal{N}(0, I)\end{aligned}$$

Porém o problema pode ser bem difícil. Principalmente em altas dimensões.



Convergência de Monte Carlo




Convergência de Monte Carlo






Convergência de Monte Carlo



Importance Sampling Convergence for Different Proposal Distributions



Convergência de Monte Carlo



O que fazer...

Precisamos encontrar uma distribuição $Q(z)$ que facilite o cálculo da integral:

$$P(x|\theta) = \int P(x|z, \theta)P(z|\theta)dz$$

O que fazer...

Precisamos encontrar uma distribuição $Q(z)$ que facilite o cálculo da integral:

$$\begin{aligned}P(x|\theta) &= \int P(x|z, \theta)P(z|\theta)dz \\&= \int \frac{P(x|z, \theta)P(z|\theta)Q(z)}{Q(z)}dz \\&= \mathbb{E}_{z \sim Q} \left[\frac{P(x|z, \theta)P(z|\theta)}{Q(z)} \right] \\&\approx \frac{1}{M} \sum_{i=1}^M \frac{P(x|z_i, \theta)P(z_i|\theta)}{Q(z_i)}, z_i \sim Q(z)\end{aligned}$$

Idealmente $Q(z) = P(z|x, \theta)$ para este x . Portanto faz sentido esperar que Q dependa de x , ou seja procuramos por $Q(z|x)$.

Procurando por Q

Definição: Dadas duas distribuições $P(z)$ e $Q(z)$ quaisquer. A divergência de Kullback-Leibler (KL) é dada por:

$$\begin{aligned}\mathcal{D}_{KL}[Q||P] &= \mathbf{E}_{z \sim Q}[\log Q(z) - \log P(z)] \\ &= \int \log \left(\frac{Q(z)}{P(z)} \right) Q(z) dz\end{aligned}$$

$\mathcal{D}_{KL}[Q||P]$ mede a “distância” entre as distribuições P e Q .

Se Q depende de um parâmetro ϕ , ou seja $Q = Q(z|\phi)$, então minimizar $\mathcal{D}[Q||P]$ equivale a tornar Q próxima de P .

Propriedade: $\mathcal{D}_{KL}[Q||P] \geq 0$ e $\mathcal{D}_{KL}[Q||P] = 0$ se e somente se $Q = P$.

Procurando por Q

Temos que

$$\begin{aligned} D_{\text{KL}} [Q(z|x) \parallel P(z|x, \theta)] &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(z|x, \theta)] \\ &= \mathbf{E}_{z \sim Q} \left[\log Q(z|x) - \log \frac{P(x|z, \theta)P(z|\theta)}{P(x|\theta)} \right] \\ &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(x|z, \theta) - \log P(z|\theta) + \log P(x|\theta)] \\ &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(x|z, \theta) - \log P(z|\theta)] + \log P(x|\theta) \end{aligned}$$

Portanto:

$$\begin{aligned} \log P(x|\theta) - D_{\text{KL}} [Q(z|x) \parallel P(z|x, \theta)] &= \\ &= \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x) \parallel P(z|\theta)] \end{aligned}$$

Procurando por Q

Temos que

$$\begin{aligned} D_{\text{KL}} [Q(z|x) \parallel P(z|x, \theta)] &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(z|x, \theta)] \\ &= \mathbf{E}_{z \sim Q} \left[\log Q(z|x) - \log \frac{P(x|z, \theta)P(z|\theta)}{P(x|\theta)} \right] \\ &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(x|z, \theta) - \log P(z|\theta) + \log P(x|\theta)] \\ &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(x|z, \theta) - \log P(z|\theta)] + \log P(x|\theta) \end{aligned}$$

Portanto:

$$\underbrace{\log P(x|\theta)}_{\text{Modelo generativo}} - \underbrace{D_{\text{KL}} [Q(z|x) \parallel P(z|x, \theta)]}_{\text{Erro de aproximação}} = \underbrace{\mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x) \parallel P(z|\theta)]}_{\text{Evidence Lower Bound (ELBO)}}$$

Reorganizando

$$\begin{array}{c} \text{Modelo generativo} \qquad \text{Erro de aproximação} \\ \underbrace{\log P(x|\theta)} - \underbrace{D_{\text{KL}} [Q(z|x) \parallel P(z|x, \theta)]} = \\ \underbrace{\mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x) \parallel P(z|\theta)]}_{\text{Evidence Lower Bound (ELBO)}} \end{array}$$

Nosso objetivo é maximizar $P(x|\theta)$, mas para isso precisamos parametrizar $Q(z|x)$. Ou seja, tomamos

$$Q(z|x) = Q(z|x, \phi)$$

Dessa forma, podemos escrever

$$\text{ELBO} [\theta, \phi] = \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]$$

Reorganizando

$$\overbrace{\log P(x|\theta)}^{\text{Modelo generativo}} - \overbrace{D_{\text{KL}}[Q(z|x, \phi) \parallel P(z|x, \theta)]}^{\text{Erro de aproximação}} = \text{ELBO}[\theta, \phi]$$

Temos que

$$D_{\text{KL}}[Q(z|x, \phi) \parallel P(z|x, \theta)] \geq 0,$$

portanto

$$\log P(x|\theta) \geq \text{ELBO}[\theta, \phi]$$

Ou seja, maximizar $\text{ELBO}[\theta, \phi]$ **ajuda** a maximizar $P(x|\theta)$. Mas e o erro de aproximação?

Reorganizando

Fixados x e θ em

$$\log P(x|\theta) - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|x, \theta)] = \text{ELBO} [\theta, \phi]$$

Temos que

$$\text{ELBO} [\theta, \phi] \uparrow \Rightarrow D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|x, \theta)] \downarrow$$

pois $\log P(x|\theta)$ é constante. E neste caso, temos que

$$D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|x, \theta)] \rightarrow 0$$

ou seja, $Q(z|x, \phi)$ se aproxima da verdadeira $P(z|x, \theta)$.

Por outro lado, fixados z e ϕ , podemos ver que

$$\text{ELBO} [\theta, \phi] \uparrow \Rightarrow \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] \uparrow$$

Que pode ser entendido como a fidelidade da reconstrução de x a partir de z .

Resumindo

Até aqui, temos que

- ▶ $\log P(x|\theta)$ é o modelo generativo
- ▶ $Q(z|x, \phi)$ modela a distribuição de z dado x
- ▶ $P(x|z, \theta)$ modela a distribuição x a partir de z
- ▶ $P(z|\theta)$ é a distribuição a priori de z

Para transformar tudo isso em um modelo prático precisamos fazer algumas escolhas:

- ▶ $Q(z|x, \phi) = \mathcal{N}(g_\mu(x, \phi), g_\sigma^2(x, \phi))$
- ▶ $P(x|z, \theta) = \mathcal{N}(f_\mu(z, \theta), f_\sigma^2(z, \theta))$

Onde $g_\mu(x, \phi)$ e $g_\sigma^2(x, \phi)$ são redes neurais.

E

- ▶ $P(z|\theta) = \mathcal{N}(0, I)$

É uma escolha arbitrária que simplifica o modelo.

Referências I

- [1] Simon Prince. *Understanding Deep Learning*. 2023. URL: <https://udlbook.github.io/udlbook/> (visited on 12/20/2023).