

Modelos Generativos: Variational Autoencoders

Machine Learning 2 2026.1

Francisco Ganacim, Daniel Yukimura

IMPA

May 27, 2026

Recapitulando a Aula passada I

- ▶ Queremos aprender a distribuição $P(x|\theta)$, onde θ são os parâmetros do modelo.
- ▶ Criamos a variável latente z e usamos a $P(x, z)$ para escrever:

$$P(x|\theta) = \int P(x|z, \theta)P(z|\theta)dz$$

- ▶ Vimos que não podemos calcular a integral diretamente.
- ▶ Introduzimos uma distribuição $Q(z|x, \phi)$, que é uma aproximação de $P(z|x, \theta)$. E escrevemos:

$$\begin{aligned} P(x|\theta) &= \int \frac{P(x|z, \theta)P(z|\theta)Q(z|x, \phi)}{Q(z|x, \phi)}dz \\ &= \mathbb{E}_{z \sim Q} \left[\frac{P(x|z, \theta)P(z|\theta)}{Q(z|x, \phi)} \right] \end{aligned}$$

Recapitulando a Aula passada II

- Desta forma a aproximação:

$$\begin{aligned} P(x|\theta) &= \int P(x|z, \theta) P(z|\theta) dz \\ &\approx \frac{1}{M} \sum_{i=1}^M \frac{P(x|z_i, \theta) P(z_i|\theta)}{Q(z_i|x, \phi)}, \quad z_i \sim Q(z|x, \phi) \end{aligned}$$

Pode ser calculado com **poucas** amostras de z .

Recapitulando a Aula passada

Temos que

$$\begin{aligned} D_{\text{KL}} [Q(z|x) \parallel P(z|x, \theta)] &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(z|x, \theta)] \\ &= \mathbf{E}_{z \sim Q} \left[\log Q(z|x) - \log \frac{P(x|z, \theta) P(z|\theta)}{P(x|\theta)} \right] \\ &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(x|z, \theta) - \log P(z|\theta) + \log P(x|\theta)] \\ &= \mathbf{E}_{z \sim Q} [\log Q(z|x) - \log P(x|z, \theta) - \log P(z|\theta)] + \log P(x|\theta) \end{aligned}$$

Portanto:

$$\underbrace{\log P(x|\theta)}_{\text{Modelo generativo}} - \underbrace{D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|x, \theta)]}_{\text{Erro de aproximação}} = \underbrace{\mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]}_{\text{Evidence Lower Bound (ELBO)}}$$

Reorganizando

$$\overbrace{\log P(x|\theta)}^{\text{Modelo generativo}} - \overbrace{D_{\text{KL}}[Q(z|x, \phi) \parallel P(z|x, \theta)]}^{\text{Erro de aproximação}} = \text{ELBO}[\theta, \phi]$$

Temos que

$$D_{\text{KL}}[Q(z|x, \phi) \parallel P(z|x, \theta)] \geq 0,$$

portanto

$$\log P(x|\theta) \geq \text{ELBO}[\theta, \phi]$$

Ou seja, maximizar $\text{ELBO}[\theta, \phi]$ **ajuda** a maximizar $P(x|\theta)$.

Mas, e o erro de aproximação?

Reorganizando

Afirmção: Maximizar ELBO $[\theta, \phi]$ em relação a ϕ aproxima $Q(z|x, \phi)$ de $P(z|x, \theta)$.

Reorganizando

Afirmção: Maximizar ELBO $[\theta, \phi]$ em relação a ϕ aproxima $Q(z|x, \phi)$ de $P(z|x, \theta)$.

Fixados x, z e θ em

$$\log P(x|\theta) - D_{\text{KL}}[Q(z|x, \phi) \| P(z|x, \theta)] = \text{ELBO}[\theta, \phi]$$

Temos que

$$\text{ELBO}[\theta, \phi] \uparrow \Rightarrow D_{\text{KL}}[Q(z|x, \phi) \| P(z|x, \theta)] \downarrow$$

pois $\log P(x|\theta)$ é constante. E neste caso, **gostaríamos** que

$$D_{\text{KL}}[Q(z|x, \phi) \| P(z|x, \theta)] \rightarrow 0$$

ou seja, que $Q(z|x, \phi)$ se aproxime da verdadeira $P(z|x, \theta)$.

Reorganizando

Afirmção: Maximizar ELBO $[\theta, \phi]$ em relação a ϕ aproxima $Q(z|x, \phi)$ de $P(z|x, \theta)$.

Por outro lado, fixados x, z e ϕ em

$$\log P(x|\theta) - D_{\text{KL}} [Q(z|x, \phi) \| P(z|x, \theta)] = \text{ELBO} [\theta, \phi]$$

Temos que

$$\text{ELBO} [\theta, \phi] \uparrow \Rightarrow \log P(x|\theta) \uparrow \text{ ou } D_{\text{KL}} [Q(z|x, \phi) \| P(z|x, \theta)] \downarrow$$

Reorganizando

Afirmção: Maximizar ELBO $[\theta, \phi]$ em relação a ϕ aproxima $Q(z|x, \phi)$ de $P(z|x, \theta)$.

Por outro lado, fixados x, z e ϕ em

$$\log P(x|\theta) - D_{\text{KL}} [Q(z|x, \phi) \| P(z|x, \theta)] = \text{ELBO} [\theta, \phi]$$

Temos que

$$\text{ELBO} [\theta, \phi] \uparrow \Rightarrow \log P(x|\theta) \uparrow \text{ ou } D_{\text{KL}} [Q(z|x, \phi) \| P(z|x, \theta)] \downarrow$$


Mas,

$$\text{ELBO} [\theta, \phi] = \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - \underbrace{D_{\text{KL}} [Q(z|x, \phi) \| P(z|\theta)]}_{\text{fixo}}$$

o que sugere que,

$$\text{ELBO} [\theta, \phi] \uparrow \Rightarrow \log P(x|\theta) \uparrow \text{ e } D_{\text{KL}} [Q(z|x, \phi) \| P(z|x, \theta)] \uparrow$$

Curves/Loss



Run ↑

Run	Value	Step	Time	Relative
● tensorboard/Curves_Loss_Train	316.4	205	5/12/25, 1:32 PM	7.85 min
● tensorboard/Curves_Loss_Validation	344.5	205	5/12/25, 1:32 PM	7.85 min

Value

Step

Relative

301.8866

218



8.383 min

331.2506

218

8.383 min

Curves/Loss



Run ↑

● tensorboard/Curves_Loss_KLDivergence_Train
● tensorboard/Curves_Loss_KLDivergence_Validation

Value

Step

Relative

59.1485

218

8.38 min

59.0558

218

8.382 min

Resumindo

Até aqui, temos que

- ▶ $\log P(x|\theta)$ é o modelo generativo
- ▶ $Q(z|x, \phi)$ modela a distribuição de z dado x
- ▶ $P(x|z, \theta)$ modela a distribuição x a partir de z
- ▶ $P(z|\theta)$ é a distribuição a priori de z

Para transformar tudo isso em um modelo prático precisamos fazer algumas escolhas:

- ▶ $Q(z|x, \phi) = \mathcal{N}(g_\mu(x, \phi), g_\sigma^2(x, \phi))$
- ▶ $P(x|z, \theta) = \mathcal{N}(f_\mu(z, \theta), f_\sigma^2(z, \theta))$


Onde $g_\mu(x, \phi)$ e $g_\sigma^2(x, \phi)$ são redes neurais.

E

- ▶ $P(z|\theta) = \mathcal{N}(0, I)$


É uma escolha arbitrária que simplifica o modelo.

Variational Autoencoders



$$\text{ELBO} [x, z, \theta, \phi] = \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]$$

Variational Autoencoders



$$\text{ELBO}[x, z, \theta, \phi] = \underbrace{\mathbf{E}_{z \sim Q} [\log P(x|z, \theta)]}_{\text{Loss de reconstrução}} - \underbrace{D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]}_{\text{Divergência do espaço latente}}$$

Variational Autoencoders

$$\text{ELBO} [x, z, \theta, \phi] = \underbrace{\mathbf{E}_{z \sim Q} [\log P(x|z, \theta)]}_{\text{Loss de reconstrução}} - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]$$

$$\begin{aligned} \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] &\approx \frac{1}{M} \sum_{i=1}^M \log P(x|z_i, \theta), \quad z_i \sim Q(z|x, \phi) \\ &\approx \log P(x|z_i, \theta), \quad z_i \sim Q(z|x, \phi) \end{aligned}$$

Pois $Q(z|x, \phi)$ é uma distribuição gaussiana, que produz **bons** valores de z , com baixa variância.

Variational Autoencoders

$$\text{ELBO} [x, z, \theta, \phi] = \underbrace{\mathbf{E}_{z \sim Q} [\log P(x|z, \theta)]}_{\text{Loss de reconstrução}} - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]$$

$$\begin{aligned} \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] &\approx \frac{1}{M} \sum_{i=1}^M \log P(x|z_i, \theta), \quad z_i \sim Q(z|x, \phi) \\ &\approx \log P(x|z_i, \theta), \quad z_i \sim Q(z|x, \phi) \\ &\approx -\frac{D_x}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|x - f(z, \theta)\|^2 \end{aligned}$$

Pois $Q(z|x, \phi)$ é uma distribuição gaussiana, que produz **bons** valores de z , com baixa variância.

Onde D_x é a dimensão de x e $\sigma^2 * I$ (hiperparâmetro) é variância da distribuição.

Variational Autoencoders

$$\text{ELBO} [x, z, \theta, \phi] = \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - \underbrace{D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)]}_{\text{Divergência do espaço latente}}$$

$$D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)] = \frac{1}{2} (\text{Tr}[\Sigma] + \mu^T \mu - D_z - \log \det \Sigma)$$

Onde D_z é a dimensão de z , $\mu = g_\mu(x, \phi)$ e $\Sigma = g_\sigma(x, \phi)$.

Variational Autoencoders: Treino

Portanto,

$$\begin{aligned}\text{ELBO}[x, z, \theta, \phi] &= \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)] \\ &\approx -\frac{D_x}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|x - f(z, \theta)\|^2 \\ &\quad - \frac{1}{2} (\text{Tr}[\Sigma] + \mu^T \mu - D_z - \log \det \Sigma)\end{aligned}$$

onde $z_i \sim Q(z|x, \phi)$.

E,

$$\begin{aligned}\arg \min_{\theta, \phi} \text{ELBO}[x, z, \theta, \phi] \\ = \arg \min_{\theta, \phi} \left(-\frac{1}{2\sigma^2} \|x - f(z, \theta)\|^2 - \frac{1}{2} (\text{Tr}[\Sigma] + \mu^T \mu - D_z - \log \det \Sigma) \right)\end{aligned}$$

Variational Autoencoders: Treino

Portanto,

$$\begin{aligned}\text{ELBO}[x, z, \theta, \phi] &= \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)] \\ &\approx -\frac{D_x}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|x - f(z, \theta)\|^2 \\ &\quad - \frac{1}{2} (\text{Tr}[\Sigma] + \mu^T \mu - D_z - \log \det \Sigma)\end{aligned}$$


onde $z_i \sim Q(z|x, \phi)$.

E,

$$\begin{aligned}\arg \min_{\theta, \phi} \text{ELBO}[x, z, \theta, \phi] \\ = \arg \min_{\theta, \phi} \left(-\frac{1}{2\sigma^2} \|x - f(z, \theta)\|^2 - \frac{1}{2} (\text{Tr}[\Sigma] + \mu^T \mu - D_z - \log \det \Sigma) \right)\end{aligned}$$

É possível computar o gradiente de ELBO em relação a θ e ϕ usando backpropagation?

Variational Autoencoders



$$\begin{aligned} \text{ELBO}[x, z, \theta, \phi] &= \mathbf{E}_{z \sim Q} [\log P(x|z, \theta)] - D_{\text{KL}} [Q(z|x, \phi) \parallel P(z|\theta)] \\ &\approx -\frac{D_x}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|x - f(z, \theta)\|^2 \\ &\quad - \frac{1}{2} (\text{Tr}[\Sigma] + \mu^T \mu - D_z - \log \det \Sigma) \end{aligned}$$

onde $z_i = g_\mu(x, \theta) + \epsilon * g_\sigma(x, \theta), \epsilon \sim N(0, I)$.

Exemplos e Código

Computando a $P(x)$ usando o VAE

Dados um x qualquer podemos computar a $P(x)$ usando o VAE.


$$\begin{aligned} P(x) &= \int P(x|z, \theta) P(z|\theta) dz \\ &\approx \frac{1}{M} \sum_{i=1}^M P(x|z_i, \theta), \quad z_i \sim P(z|\theta) = \mathcal{N}(0, I) \end{aligned}$$

Como gerar boas amostras?



[1] 2016 — Alex Lamb et al. — *Discriminative Regularization for Generative Models*

Como gerar boas amostras?



[1] 2016 — Alex Lamb et al. — *Discriminative Regularization for Generative Models*

Referências I

- [1] Alex Lamb, Vincent Dumoulin, and Aaron Courville. *Discriminative Regularization for Generative Models*. arXiv:1602.03220 [stat]. Feb. 2016. DOI: 10.48550/arXiv.1602.03220. URL: <http://arxiv.org/abs/1602.03220> (visited on 05/11/2025).