


Large Language Models

Aula 18 - Machine Learning II

Daniel Yukimura, Francisco Ganacim
IMPA

15 de junho de 2026

LLMs pipeline:



Prompt: “Como faço para trocar um pneu?”

Resposta:

Prompt: “Como faço para trocar um pneu?”

Resposta:

“Como faço para trocar o óleo? Como faço para calibrar os pneus? Estas são perguntas comuns entre motoristas iniciantes...”

Prompt: “Como faço para trocar um pneu?”

Resposta:

“Como faço para trocar o óleo? Como faço para calibrar os pneus? Estas são perguntas comuns entre motoristas iniciantes...”

- LLMs pré-treinadas não respondem perguntas naturalmente.


Prompt: “Como faço para trocar um pneu?”

Resposta:


“Como faço para trocar o óleo? Como faço para calibrar os pneus? Estas são perguntas comuns entre motoristas iniciantes...”

- LLMs pré-treinadas não respondem perguntas naturalmente.
- O modelo aprendeu $p(x_t | x_{<t})$ sobre a distribuição de textos na web — ele completa texto.

LLMs pipeline:



LLMs pipeline:



Prompt-Engineering

- Podemos construir um prompt que aumenta a chance de uma resposta correta?

$$p_{\theta}(\text{resposta} \mid \text{prompt})$$

Prompt-Engineering

- Podemos construir um prompt que aumenta a chance de uma resposta correta?

$$p_{\theta}(\text{resposta} \mid \text{prompt})$$

- Como escolher uma sequência de tokens de entrada que restringe o modelo a dar a resposta desejada?

Prompt-Engineering

Prompt: “Questão: Como faço para trocar um pneu?
Resposta:”

Resposta:

Prompt-Engineering

Prompt: “Questão: Como faço para trocar um pneu?
Resposta:”

Resposta:

“ Afrouxe os parafusos com o carro no chão, posicione o macaco no ponto correto e levante até o pneu sair do chão. Remova o pneu furado, coloque o estepe, aperte os parafusos em cruz....”

Prompt-Engineering

Prompt: “Questão: Como faço para trocar um pneu?
Resposta:”

Resposta:

“ Afrouxe os parafusos com o carro no chão, posicione o macaco no ponto correto e levante até o pneu sair do chão. Remova o pneu furado, coloque o estepe, aperte os parafusos em cruz....”

- Reformular a pergunta ou instrução como um diálogo, ou de forma que se assemelhe a estrutura dos textos em que a LLM pode ser suficiente.

Prompt-Engineering

Prompt: “Questão: Como faço para trocar um pneu?
Resposta:”

Resposta:

“ Afrouxe os parafusos com o carro no chão, posicione o macaco no ponto correto e levante até o pneu sair do chão. Remova o pneu furado, coloque o estepe, aperte os parafusos em cruz....”

- Reformular a pergunta ou instrução como um diálogo, ou de forma que se assemelhe a estrutura dos textos em que a LLM pode ser suficiente.
- **Em geral isso não costuma ser tão fácil!**

Prompt-Engineering

Prompt: 'Classifique o sentimento como “positivo” ou “negativo”.\n
 Texto: O filme foi incrível! Um dos melhores que assisti esse ano.\n
 Sentimento: '

Resposta:

Prompt-Engineering

Prompt: 'Classifique o sentimento como “positivo” ou “negativo”.\n
Texto: O filme foi incrível! Um dos melhores que assisti esse ano.\n
Sentimento: '

Resposta:

“ Positivo\n
Texto: O filme não foi bom...”

Prompt-Engineering

Prompt: 'Classifique o sentimento como “positivo” ou “negativo”.\n
Texto: O filme foi incrível! Um dos melhores que assisti esse ano.\n
Sentimento: '

Resposta:

“ Positivo\n
Texto: O filme não foi bom...”

- Que tipos de tarefas conseguimos resolver apenas com pré-treino?

In-Context Learning (ICL)

In-Context Learning (ICL)

- GPT-3: tarefas novas podem ser aprendidas dentro do contexto, sem atualizar parâmetros.

Zero-shot:

Traduza para o inglês:
queijo →


One-shot:

Traduza para o inglês:
mar → sea
queijo →

Few-shot:


Traduza para o inglês:
mar → sea
gato → cat
frango → chicken
queijo →

In-Context Learning (ICL)



- Modelos maiores parecem extrair informação melhor do prompt.

In-Context Learning (ICL)



- Few-shot pode até superar modelos com fine-tuning supervisionado

In-Context Learning (ICL)

Por que isso é surpreendente?

- O objetivo do treino é apenas prever o próximo token.
- Em nenhum momento o modelo foi treinado para “aprender com exemplos”
- Não há atualizações de parâmetros: O “aprendizado” acontece durante a inferência.

In-Context Learning (ICL)

Por que isso ocorre?

- ICL como **inferência Bayesiana**:

$$p(x_t | \text{prompt}) = \int_{\Omega} p(x_t | \text{prompt}, \omega) p(\omega | \text{prompt}) d\omega$$

- Se o corpus de pré-treino é gerado por uma mistura de “conceitos” latentes ω (tarefas, tópicos, formatos). Então os exemplos no prompt ajudam a **selecionar o conceito** certo.

In-Context Learning (ICL)


Por que isso ocorre?

- Transformers aprendem a aprender
- Se treinamos um transformer para completar $(x_1, f(x_1), \dots, x_k, f(x_k), x_{k+1})$ com f linear:

In-Context Learning (ICL)

Por que isso ocorre?

- Transformers aprendem a aprender
- Se treinamos um transformer para completar $(x_1, f(x_1), \dots, x_k, f(x_k), x_{k+1})$ com f linear:



In-Context Learning (ICL)

Por que isso ocorre?

- Transformers aprendem a aprender
- Se treinamos um transformer para completar $(x_1, f(x_1), \dots, x_k, f(x_k), x_{k+1})$, para diferentes funções f , podemos aprender a realizar em tempo de inferência:
 - Least Squares, Least Regression, Generalized linear models, Lasso, **Gradient Descent**, ...
- Como isso acontece? Olsson et al (2022) identificam um tipo de circuito de indução ($[A][B] \dots [A] \rightarrow [B]$), que parecem se formar na mesma transição de fase que ICL.

Chain-of-Thought (CoT)

- Ao invés de usar exemplos do tipo (pergunta → resposta), usamos (pergunta → **raciocínio** → resposta)

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?


A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

Chain-of-Thought (CoT)



- CoT é uma habilidade emergente — começa a fazer diferença para modelos grandes
- **Zero-shot CoT:** Ao final do prompt adicione: “Let's think step by step”

Self-consistency

Escalando CoT

Ideia: Amostrar diferentes raciocínios e fazer uma votação sobre as respostas

1. Use um prompt com CoT
2. Amostre k diferentes cadeias de raciocínio — Usando temperatura/top-k/núcleo
3. Extraia a resposta final de cada cadeia
4. Responda pela maioria


$$\hat{y} = \arg \max_y \#\{i : y^{(i)} = y\}, \quad y^{(i)} \sim p_{\theta}(\cdot \mid \text{prompt CoT})$$

Supervised Fine-Tuning (SFT)

Supervised Fine-Tuning (SFT)

A abordagem padrão **Pré-treino** → **Fine-Tuning** pode funcionar bem.

- Restringe o modelo a uma tarefa fixa
- Feito em geral com transformers com encoder, como o modelo BERT



Supervised Fine-Tuning (SFT)

Instruction-Tuning

Dado pares de (instrução, resposta) podemos modificar o problema de máxima verossimilhança para um problema supervisionado


$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{(x,y) \in \mathcal{D}} \sum_t \log p_{\theta}(y_t \mid x, y_{<t})$$

- **Loss masking:** a perda é calculada apenas nos tokens da resposta y , e não no prompt x
- A arquitetura e o otimizador não mudam.
- Os dados podem incluir múltiplas tarefas

Instruction Tuning

Como fazer uma LLM seguir instruções?

- Dataset supervisionado com **múltiplas tarefas**.
- (Input, output) → (instruction, output) — Instruções com diferentes templates aumentam o conjunto de dados



Instruction Tuning

Premise

Russian cosmonaut Valery Polyakov set the record for the longest continuous amount of time spent in space, a staggering 438 days, between 1994 and 1995.

Hypothesis

Russians hold the record for the longest stay in space.

Target

Entailment
Not entailment



Options:
- yes
- no



Template 1

<premise>

Based on the paragraph above, can we conclude that **<hypothesis>**?

<options>

Template 2

<premise>

Can we infer the following?

<hypothesis>

<options>

Template 3

Read the following and determine if the hypothesis can be inferred from the premise:


Premise: **<premise>**

Hypothesis: **<hypothesis>**

<options>

Template 4, ...

Instruction Tuning



Instruction Tuning

Release	Collection	Model Details				Data Collection & Training Details			
		Model	Base	Size	Public?	Prompt Types	Tasks in Flan	# Exs	Methods
2020 05	UnifiedQA	UnifiedQA	RoBerta	110-340M	P	ZS	46 / 46	750k	
2021 04	CrossFit	BART-CrossFit	BART	140M	NP	FS	115 / 159	71M	
2021 04	Natural Inst v1.0	Gen. BART	BART	140M	NP	ZS / FS	61 / 61	620k	+ Detailed k-shot Prompts
2021 09	Flan 2021	Flan-LaMDA	LaMDA	137B	NP	ZS / FS	62 / 62	4.4M	+ Template Variety
2021 10	P3	T0, T0+, T0++	T5-LM	3-11B	P	ZS	62 / 62	12M	+ Template Variety + Input Inversion
2021 10	MetalCL	MetalCL	GPT-2	770M	P	FS	100 / 142	3.5M	+ Input Inversion + Noisy Channel Opt
2021 11	ExMix	ExT5	T5	220M-11B	NP	ZS	72 / 107	500k	+ With Pretraining
2022 04	Super-Natural Inst.	Tk-Instruct	T5-LM, mT5	11-13B	P	ZS / FS	1556 / 1613	5M	+ Detailed k-shot Prompts + Multilingual
2022 10	GLM	GLM-130B	GLM	130B	P	FS	65 / 77	12M	+ With Pretraining + Bilingual (en, zh-cn)
2022 11	xP3	BLOOMz, mT0	BLOOM, mT5	13-176B	P	ZS	53 / 71	81M	+ Massively Multilingual
2022 12	Unnatural Inst.†	T5-LM-Unnat. Inst.	T5-LM	11B	NP	ZS	~20 / 117	64k	+ Synthetic Data
2022 12	Self-Instruct†	GPT-3 Self Inst.	GPT-3	175B	NP	ZS	Unknown	82k	+ Synthetic Data + Knowledge Distillation
2022 12	OPT-IML Bench†	OPT-IML	OPT	30-175B	P	ZS + FS CoT	~2067 / 2207	18M	+ Template Variety + Input Inversion + Multilingual
2022 10	Flan 2022 (ours)	Flan-T5, Flan-PaLM	T5-LM, PaLM	10M-540B	P NP	ZS + FS CoT	1836	15M	+ Template Variety + Input Inversion + Multilingual

Instruction Tuning

- InstructGPT — Respostas escritas por anotadores para prompts reais — RLHF (próxima aula)
- LIMA — Curadoria ≫ Volume — Qualidade dos dados parece ser mais importante nessa etapa.
- Self-Instruct — Gera dados sintéticos a partir de um banco de instruções, filtra os resultados de baixa qualidade e aumenta o dataset de treino.

SFT na prática

Ex: Fine-tuning de um modelo com 70B parâmetros usando AdamW

SFT na prática

Ex: Fine-tuning de um modelo com 70B parâmetros usando AdamW

- Pesos bf16 (trabalho): $2 \times 70\text{B} = 140\text{ GB}$
- Gradientes bf16: $2 \times 70\text{B} = 140\text{ GB}$
- Pesos mestres fp32: $4 \times 70\text{B} = 280\text{ GB}$
- 1º momento de Adam (m), fp32: $4 \times 70\text{B} = 280\text{ GB}$
- 2º momento de Adam (v), fp32: $4 \times 70\text{B} = 280\text{ GB}$

SFT na prática

Ex: Fine-tuning de um modelo com 70B parâmetros usando AdamW

- Pesos bf16 (trabalho): $2 \times 70\text{B} = 140\text{ GB}$
- Gradientes bf16: $2 \times 70\text{B} = 140\text{ GB}$
- Pesos mestres fp32: $4 \times 70\text{B} = 280\text{ GB}$
- 1º momento de Adam (m), fp32: $4 \times 70\text{B} = 280\text{ GB}$
- 2º momento de Adam (v), fp32: $4 \times 70\text{B} = 280\text{ GB}$

Total dos estados do modelo $16 \times 70\text{B} = 1.1\text{ TB}$

SFT na prática

Ex: Fine-tuning de um modelo com 70B parâmetros usando AdamW

SFT na prática

Ex: Fine-tuning de um modelo com 70B parâmetros usando AdamW

- Usando H100 de 80 GB: ~14 GPUs só para armazenar os estados; na prática 16–32 GPUs (2–4 nós com NVLink).

SFT na prática

Ex: Fine-tuning de um modelo com 70B parâmetros usando AdamW

- Usando H100 de 80 GB: ~14 GPUs só para armazenar os estados; na prática 16–32 GPUs (2–4 nós com NVLink).
- Custo: H100 a ~US\$ 2,50/h (faixa US\$ 1,40–3,50). 24 GPUs $\approx$ US\$ 60/h $\rightarrow$ execução de 3 dias $\approx 24 \times 72 \times 2,50 \approx$ US\$ 4.300.

LoRA: Low-Rank Adaptation

Ideia: E se a atualização ΔW tivesse posto baixo?

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r} BA, \quad B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}$$

- Apenas A e B são treinados: $r(d + k)$ parâmetros em vez de dk
- Ex.: $d = k = 4096$, $r = 8$: 65.5k vs 16.8M por matriz ($\sim 0.4\%$)
- Tipicamente aplicado às projeções de atenção — W_q, W_k

LoRA: Low-Rank Adaptation

- **Memória:** otimizador só guarda os estados de A e B
- **Inferência:** após o treino, faça o merge $W \leftarrow W_0 + \frac{\alpha}{r}BA$ — **custo zero** de latência
- **Modularidade:** Podemos ter um adaptador pequeno (MBs) por tarefa, sobre o mesmo modelo base.
- **QLoRA:** modelo base quantizado em 4 bits + adaptadores LoRA em bf16 → fine-tuning de 70B → 45-55GB de memória, cabe em uma única H100 de 80 GB.