


# Large Language Models

Aula 19 - Machine Learning II

Daniel Yukimura, Francisco Ganacim  
IMPA

17 de junho de 2026

# LLMs pipeline:



# Alinhamento

**Prompt:** “ Explique por que o céu é azul para uma criança de 8 anos ”

**Resposta A:**

“ A luz do Sol parece branca, mas é feita de várias cores. Quando ela entra na atmosfera, a cor azul se espalha para todo lado, como bolinhas quicando. Por isso, de onde você olha, o céu fica azul!”

**Resposta B:**

“O espalhamento de Rayleigh é inversamente proporcional à quarta potência do comprimento de onda, logo a radiação de menor  $\lambda$  é predominantemente espalhada...”

# Alinhamento

**Prompt:** “ Explique por que o céu é azul para uma criança de 8 anos ”

**Resposta A:**

“ A luz do Sol parece branca, mas é feita de várias cores. Quando ela entra na atmosfera, a cor azul se espalha para todo lado, como bolinhas quicando. Por isso, de onde você olha, o céu fica azul!”

**Resposta B:**

“O espalhamento de Rayleigh é inversamente proporcional à quarta potência do comprimento de onda, logo a radiação de menor  $\lambda$  é predominantemente espalhada...”

- Ambas as respostas podem ter alta verossimilhança. SFT não costuma ser suficiente para distinguir que **A**  $\succ$  **B**.

# Alinhamento

- Além de seguir instruções, gostaríamos que as LLMs as fizessem de maneira **útil, honesta e inofensiva — HHH** (Helpful, Honest, Harmless).

# Alinhamento

- Além de seguir instruções, gostaríamos que as LLMs as fizessem de maneira **útil, honesta e inofensiva — HHH** (Helpful, Honest, Harmless).
- Gostaríamos de ter uma função  $R(x, y)$  que mede se a  $y$  é uma boa resposta para  $x$ .

# Alinhamento

- Além de seguir instruções, gostaríamos que as LLMs as fizessem de maneira **útil, honesta e inofensiva — HHH** (Helpful, Honest, Harmless).
- Gostaríamos de ter uma função  $R(x, y)$  que mede se a  $y$  é uma boa resposta para  $x$ .
- Em geral, não conseguimos escrever explicitamente uma perda para medir HHH.

# Alinhamento

- Além de seguir instruções, gostaríamos que as LLMs as fizessem de maneira **útil, honesta e inofensiva — HHH** (Helpful, Honest, Harmless).
- Gostaríamos de ter uma função  $R(x, y)$  que mede se a  $y$  é uma boa resposta para  $x$ .
- Em geral, não conseguimos escrever explicitamente uma perda para medir HHH.
- Comparar se uma resposta é melhor do que outra é mais factível — **preferência**

# Alinhamento

- Além de seguir instruções, gostaríamos que as LLMs as fizessem de maneira **útil, honesta e inofensiva — HHH** (Helpful, Honest, Harmless).
- Gostaríamos de ter uma função  $R(x, y)$  que mede se a  $y$  é uma boa resposta para  $x$ .
- Em geral, não conseguimos escrever explicitamente uma perda para medir HHH.
- Comparar se uma resposta é melhor do que outra é mais factível — **preferência**
- Gostaríamos de construir  $R(x, y)$  que representa bem o que preferimos (no sentido de HHH)

# Da imitação à otimização

## **Imitação (SFT):**

Encontrar  $\hat{p}(y \mid x) \approx p^*(y \mid x)$  para uma distribuição de referência  $p^*(y \mid x)$

- Perspectiva de modelagem generativa
- Requer amostras da distribuição de referência

## **Otimização (RLHF):**


Encontrar  $\hat{p}(y \mid x)$  que resolve  $\max_p \mathbb{E}_p [R(y, x)]$  para uma função de recompensa  $R(y, x)$

- LMs são vistas como políticas
- Maximizamos uma recompensa que conseguimos medir

# Reinforcement Learning with Human Feedback (RLHF)


# RLHF

## Reinforcement Learning with Human Feedback



# RLHF


## Reinforcement Learning with Human Feedback



**SFT**

# RLHF

## Reinforcement Learning with Human Feedback



# RLHF — Dados

- InstructGPT — diretrizes de anotação.
- Usando uma LLM com um prompt  $x$  o modelo gera  $k$  respostas  $y_1, \dots, y_k$  — Um anotador ordena as respostas por ordem de preferência (seguindo HHH).

| Excerpt of labeling instructions on the API prompt distribution                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>You are given a text-based description of a task, submitted by a user. This task description may be in the form of an explicit instruction (e.g. “Write a story about a wise frog.”). The task may also be specified indirectly, for example by using several examples of the desired behavior (e.g. given a sequence of movie reviews followed by their sentiment, followed by one movie review without a sentiment, you can assume the task is to predict the sentiment of the final review), or by generating the start of a desired output (e.g. given “There once was a wise frog named Julius,” you can assume the task is to continue the story).</p> <p>You will also be given several text outputs, intended to help the user with their task. Your job is to evaluate these outputs to ensure that they are <b>helpful</b>, <b>truthful</b>, and <b>harmless</b>. For most tasks, being truthful and harmless is more important than being helpful.</p> <p>By <b>helpful</b>, we mean that the output should follow the user’s intention, and help the user solve their task. Some examples of helpful behavior:</p> <ul style="list-style-type: none"><li>• Writing in clear language.</li><li>• Answering the question they meant to ask, even if they mis-asked it.</li><li>• Being sensitive to internationality (e.g. “football” shouldn’t mean American football, and “the president” doesn’t necessarily mean the US president).</li><li>• If an instruction is too confusing, asking for clarification and explaining why the instruction is confusing.</li><li>• Not giving overly long or rambling answers, or repeating information from the question.</li><li>• Not assuming extraneous extra context outside of what’s given (besides things like facts about the world), unless that’s an implied part of the task. For example, if asked to “write a polite email response to this email: email body” the output shouldn’t assume “I can’t make it this time, but am free next weekend.” But if asked to “Write an email to Socrates”, then you can safely assume the output can make up a context.</li></ul> <p>By <b>truthful</b>, we mean that the output contains accurate information, and doesn’t mislead the user. Some examples of truthful behavior:</p> <ul style="list-style-type: none"><li>• On tasks like summarization, where the output should only use information from input, not making up details that are not part of the input description.</li><li>• Not producing clearly false information about the world (e.g. making up facts or promoting conspiracies). For example, the output should not state that Hillary Clinton has served time in prison.</li><li>• Avoid generating misleading information, or information with questionable authenticity. For example, if the input asks “Why did Hillary Clinton go to jail?”, the output should not say “It’s not totally clear”, but rather should refute the premise of the question.</li></ul> <p>By <b>harmless</b>, we mean that the output should not cause physical, psychological, or social harm to people; damage to or loss of equipment or property; damage to the environment; or harm to institutions or resources necessary to human wellbeing. Some examples of harmless behavior:</p> <ul style="list-style-type: none"><li>• Treating other humans with kindness, respect and consideration; not denigrating members of certain groups, or using biased language against a particular group.</li><li>• Not generating abusive, threatening, or offensive language, or promoting violence.</li><li>• Not writing sexual or violent content if it’s not asked for.</li><li>• Not giving bad real-world advice, or promoting illegal activity.</li></ul> <p>Evaluating model outputs may involve making trade-offs between these criteria. These trade-offs will depend on the task. Use the following guidelines to help select between outputs when making these trade-offs:</p> |

# RLHF — Dados

## Desafios

- Dificuldade em encontrar anotadores de alta qualidade

# RLHF — Dados

## Desafios

- Dificuldade em encontrar anotadores de alta qualidade
- Dificuldade em garantir que anotadores verificam a exatidão das respostas

# RLHF — Dados

## Desafios

- Dificuldade em encontrar anotadores de alta qualidade
- Dificuldade em garantir que anotadores verificam a exatidão das respostas
- Como saber se a IA está sendo usada no processo

# RLHF — Dados

## Desafios

- Dificuldade em encontrar anotadores de alta qualidade
- Dificuldade em garantir que anotadores verificam a exatidão das respostas
- Como saber se a IA está sendo usada no processo
- Questões de ética de trabalho

# RLHF — Dados


## Desafios

- Dificuldade em encontrar anotadores de alta qualidade
- Dificuldade em garantir que anotadores verificam a exatidão das respostas
- Como saber se a IA está sendo usada no processo
- Questões de ética de trabalho
- Representatividade — Demografia

# RLHF — Dados


## Quem anota os dados?

% share of respondents in each age group




Sample: n = 914  
What is your age? (Single answer)  
Total may not sum due to rounding.  
Source: Oxford Economics

% share of respondents



Sample: n = 911  
What is the highest level of education you have completed? (Single answer)  
Source: Oxford Economics

% share of respondents



Sample: n = 912  
Which domain is the one where you have contributed the most? (Single answer)  
Source: Oxford Economics

# RLHF — Dados

Quem anota os dados?

BUSINESS +

TECHNOLOGY +

## Exclusive: OpenAI Used Kenyan Workers on Less Than \$2 Per Hour to Make ChatGPT Less Toxic

 ADD TIME ON GOOGLE



by **Billy Perrigo** +  
CORRESPONDENT

JAN 18, 2023 9:00 AM GMT



This image was generated by OpenAI's image-generation software, Dall-E 2. The prompt was: "A seemingly endless view of African workers at desks in front of computer screens in a printmaking style." TIME does not typically use AI-generated art to illustrate its stories, but chose to in this instance in order to draw attention to the power of OpenAI's technology and shed light on the labor that makes it possible. *Image generated by Dall-E 2/OpenAI*

# RLHF — Dados

Quem anota os dados?

BUSINESS +

TECHNOLOGY +

### Exclusive: OpenAI Used Kenyan Workers on Less Than \$2 Per Hour to Make ChatGPT Less Toxic



This image was generated by OpenAI's in front of computer screens in a printmaking to draw attention to the power of OpenAI



by Billy Perrigo +

CORRESPONDENT

JAN 18, 2023 9:00 AM GMT

Specialist Data Annotator Pay in the US (Midpoint of Ranges)

| Subject          | Expert AI Trainer (Midpoint) | Highly Skilled Expert (Midpoint) |
|------------------|------------------------------|----------------------------------|
| Legal            | 60                           | 115                              |
| Economics        | 58                           | 82                               |
| Gaming           | 55                           | 82                               |
| Physics          | 55                           | 70                               |
| Engineering      | 55                           | 115                              |
| Finance          | 50                           | 100                              |
| Computer Science | 48                           | 90                               |
| Medical          | 42                           | 120                              |
| Mathematics      | 40                           | 55                               |
| History          | 40                           | 55                               |
| Writing          | 32                           | 50                               |

<https://www.businessinsider.com/ai-data-labeling-annotators-pay-subject-experts-generalists-gig-workers-2025-12>

# RLHF — Dados

Quem anota os dados?

- Anotações por preferência também podem introduzir viés no modelo.

|                       | AI21 Labs |          |                   | OpenAI |         |              |                  |                  |                  |
|-----------------------|-----------|----------|-------------------|--------|---------|--------------|------------------|------------------|------------------|
| Model                 | j1-grande | j1-jumbo | j1-grande-v2-beta | ada    | davinci | text-ada-001 | text-davinci-001 | text-davinci-002 | text-davinci-003 |
| RELIG                 |           |          |                   |        |         |              |                  |                  |                  |
| Protestant            | 0.811     | 0.810    | 0.797             | 0.820  | 0.787   | 0.707        | 0.712            | 0.755            | 0.694            |
| Roman Catholic        | 0.812     | 0.816    | 0.806             | 0.823  | 0.792   | 0.706        | 0.714            | 0.759            | 0.701            |
| Mormon                | 0.789     | 0.789    | 0.777             | 0.802  | 0.769   | 0.697        | 0.707            | 0.751            | 0.696            |
| Orthodox              | 0.769     | 0.773    | 0.762             | 0.781  | 0.752   | 0.684        | 0.698            | 0.731            | 0.692            |
| Jewish                | 0.791     | 0.792    | 0.785             | 0.800  | 0.772   | 0.697        | 0.707            | 0.758            | 0.706            |
| Muslim                | 0.784     | 0.793    | 0.788             | 0.792  | 0.774   | 0.682        | 0.704            | 0.729            | 0.696            |
| Buddhist              | 0.770     | 0.782    | 0.776             | 0.783  | 0.764   | 0.681        | 0.701            | 0.746            | 0.709            |
| Hindu                 | 0.776     | 0.796    | 0.793             | 0.789  | 0.775   | 0.681        | 0.702            | 0.728            | 0.706            |
| Atheist               | 0.772     | 0.774    | 0.770             | 0.784  | 0.759   | 0.687        | 0.706            | 0.765            | 0.713            |
| Agnostic              | 0.782     | 0.785    | 0.781             | 0.794  | 0.767   | 0.696        | 0.714            | 0.770            | 0.716            |
| Other                 | 0.791     | 0.794    | 0.789             | 0.800  | 0.775   | 0.695        | 0.710            | 0.762            | 0.702            |
| Nothing in particular | 0.813     | 0.815    | 0.802             | 0.824  | 0.789   | 0.709        | 0.714            | 0.765            | 0.699            |

# RLHF — Dados

Quem anota os dados?

- Anotações por preferência também podem introduzir viés no modelo.

Pós-treino

|                       | AI21 Labs |          |                   | OpenAI |         |              |                  |                  |                  |
|-----------------------|-----------|----------|-------------------|--------|---------|--------------|------------------|------------------|------------------|
| Model                 | j1-grande | j1-jumbo | j1-grande-v2-beta | ada    | davinci | text-ada-001 | text-davinci-001 | text-davinci-002 | text-davinci-003 |
| RELIG                 |           |          |                   |        |         |              |                  |                  |                  |
| Protestant            | 0.811     | 0.810    | 0.797             | 0.820  | 0.787   | 0.707        | 0.712            | 0.755            | 0.694            |
| Roman Catholic        | 0.812     | 0.816    | 0.806             | 0.823  | 0.792   | 0.706        | 0.714            | 0.759            | 0.701            |
| Mormon                | 0.789     | 0.789    | 0.777             | 0.802  | 0.769   | 0.697        | 0.707            | 0.751            | 0.696            |
| Orthodox              | 0.769     | 0.773    | 0.762             | 0.781  | 0.752   | 0.684        | 0.698            | 0.731            | 0.692            |
| Jewish                | 0.791     | 0.792    | 0.785             | 0.800  | 0.772   | 0.697        | 0.707            | 0.758            | 0.706            |
| Muslim                | 0.784     | 0.793    | 0.788             | 0.792  | 0.774   | 0.682        | 0.704            | 0.729            | 0.696            |
| Buddhist              | 0.770     | 0.782    | 0.776             | 0.783  | 0.764   | 0.681        | 0.701            | 0.746            | 0.709            |
| Hindu                 | 0.776     | 0.796    | 0.793             | 0.789  | 0.775   | 0.681        | 0.702            | 0.728            | 0.706            |
| Atheist               | 0.772     | 0.774    | 0.770             | 0.784  | 0.759   | 0.687        | 0.706            | 0.765            | 0.713            |
| Agnostic              | 0.782     | 0.785    | 0.781             | 0.794  | 0.767   | 0.696        | 0.714            | 0.770            | 0.716            |
| Other                 | 0.791     | 0.794    | 0.789             | 0.800  | 0.775   | 0.695        | 0.710            | 0.762            | 0.702            |
| Nothing in particular | 0.813     | 0.815    | 0.802             | 0.824  | 0.789   | 0.709        | 0.714            | 0.765            | 0.699            |

# RLHF

## Otimização (RLHF):

Encontrar  $\hat{p}(y \mid x)$  que resolve  $\max_p \mathbb{E}_p [R(y, x)]$  para uma função de recompensa  $R(y, x)$

- LMs são vistas como políticas
- Maximizamos uma recompensa que conseguimos medir

# RLHF

## Modelando preferências: Bradley-Terry

Dados: triplas  $(x, y_w, y_l)$  — prompt, resposta preferida, resposta preterida.

Modelamos a recompensa  $r(x, y)$  a partir do modelo de Bradley-Terry:

$$p(y_w \succ y_l \mid x) = \frac{e^{r(x, y_w)}}{e^{r(x, y_w)} + e^{r(x, y_l)}} = \sigma(r(x, y_w) - r(x, y_l))$$

Treinamos  $r_\phi$  por máxima verossimilhança nas preferências observadas:

$$\mathcal{L}_R(\phi) = - \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[ \log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l)) \right]$$

# RLHF

Modelando preferências: Bradley-Terry

$$\mathcal{L}_R(\phi) = - \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[ \log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l)) \right]$$

- $r_\phi$  — a própria LLM (modelo menor) com uma cabeça escalar no lugar da cabeça do vocabulário.
- A recompensa ideal  $r^*$  é identificável a menos de uma constante (por prompt)

# RLHF


O objetivo do problema de RL

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot | x)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{\text{KL}}(\pi_{\theta}(\cdot | x) \parallel \pi_{\text{ref}}(\cdot | x))$$

- $\pi_{\text{ref}}$  é o modelo SFT (congelado) — termo de âncora
- Sem o termo de âncora, a política pode encontrar as falhas do modelo de recompensa, e explorar essa vantagem — **reward hacking**

# RLHF

## Riscos de sobre-otimização / Overfitting



# RLHF — PPO

Como otimizar?

- Geração token a token  $\rightarrow$  processo de decisão sequencial: estado  $(x, y_{<t}) \rightarrow$  ação  $y_t$ , recompensa no final da sequência.
- Treinamos usando PPO:

$$\mathcal{L}^{\text{PPO}} = \mathbb{E}_t \left[ \min \left( \rho_t \hat{A}_t, \text{clip}(\rho_t, 1 \pm \epsilon) \hat{A}_t \right) \right], \quad \rho_t = \frac{\pi_{\theta}(y_t \mid \cdot)}{\pi_{\theta_{\text{old}}}(y_t \mid \cdot)}$$

- PPO requer uma terceira rede  $V_{\psi}$  como crítico — usada para calcular a vantagem por token  $\hat{A}_t - V_{\psi}$  é inicializado igual a recompensa treinada em InstructGPT.

# RLHF — Variações

- **Arena (ELO):** usuários comparam respostas anônimas de dois modelos — preferências humanas como ranking público de modelos
- **LLM-as-judge:** usar um LLM forte para avaliar respostas — barato, escalável, mas com vieses conhecidos (posição, verbosidade, autopreferência)

*Chatbot Arena — Chiang et al. 2024*

*Judging LLM-as-a-Judge --- Zheng et al. 2023*

# Direct Preference Optimization (DPO)

# Direct Preference Optimization (DPO)

O pipeline de RLHF é pesado: reward model + RL instável + 4 modelos em memória.

Será que precisamos do RL?

Observação-chave: o objetivo KL-regularizado tem **solução em forma fechada**.

# Direct Preference Optimization (DPO)

Para o objetivo  $\max_{\pi} \mathbb{E}_{y \sim \pi}[r(x, y)] - \beta \mathbb{D}_{\text{KL}}(\pi \| \pi_{\text{ref}})$ , a solução é o **tilt exponencial** da referência:

$$\pi^*(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y \mid x) e^{r(x, y)/\beta}$$

Invertendo para expressar a recompensa em função da política:

$$r(x, y) = \beta \log \frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x)$$

**Problema:** Calcular  $Z(x)$  não é computável.

# Direct Preference Optimization (DPO)

Felizmente o termo referente é cancelado no modelo de Bradley-Terry

$$p(y_w \succ y_l \mid x) = \sigma \left( \beta \log \frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right)$$

Máxima verossimilhança **diretamente na política**:

$$\mathcal{L}_{\text{DPO}}(\theta) = - \mathbb{E}_{(x, y_w, y_l)} \left[ \log \sigma \left( \beta \log \frac{\pi_{\theta}(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_{\theta}(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right) \right]$$

# DPO vs RLHF (PPO)

## DPO

- Simples, estável, barato (2 modelos)
- *Offline*: aprende só das respostas no dataset
- Hoje padrão para alinhamento de preferências em modelos abertos

## RL (PPO etc.)

- *On-policy*: aprende das próprias gerações
- Reward model generaliza para além do dataset
- Voltou ao centro do palco para **reasoning**...

# DPO vs RLHF (PPO)

## DPO

- Simples, estável, barato (2 modelos)
- *Offline*: aprende só das respostas no dataset
- Hoje padrão para alinhamento de preferências em modelos abertos

## RL (PPO etc.)

- *On-policy*: aprende das próprias gerações
- Reward model generaliza para além do dataset
- Voltou ao centro do palco para **reasoning**...

**E se não precisássemos aprender a recompensa?**

# Reinforcement Learning with Verifiable Rewards (RLVR)

# Recompensas verificáveis (RLVR)

Para tarefas como matemática e código, a recompensa associada pode ser um **verificador** explícito, não um modelo:

$$r(x, y) = \begin{cases} 1, & \text{resposta final correta / testes passam} \\ 0, & \text{caso contrario} \end{cases}$$

- Sem anotador humano, sem reward model aprendido
- **Escalável**: milhões de episódios de RL
- **Difícil de hackear**: contraste direto com o reward model do RLHF
- Limitação evidente: só funciona onde existe um verificador

# GRPO: RL sem crítico

## Group Relative Policy Optimization

Para cada prompt  $x$ , amostra um **grupo** de  $G$  respostas  $\{y_1, \dots, y_G\} \sim \pi_{\theta_{\text{old}}}$  e normalize as recompensas dentro do grupo:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}$$

$$\mathcal{L}^{\text{GRPO}} = \mathbb{E} \left[ \frac{1}{G} \sum_{i=1}^G \min(\rho_i \hat{A}_i, \text{clip}(\rho_i, 1 \pm \epsilon) \hat{A}_i) \right] - \beta \mathbb{D}_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}})$$

- O *baseline* é a média do grupo — estatística, não um modelo aprendido
- Metade da memória do PPO; simples o bastante para reimplementação didática

# Raciocínio emergente



---



## DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

DeepSeek-AI

[research@deepseek.com](mailto:research@deepseek.com)

- Receita minimalista: modelo base + RLVR — **Sem SFT** (DeepSeek R1-Zero)
  - O modelo tende a gerar cadeias de raciocínio mais longas — CoT emergente
  - Reflexão e Backtracking.

# Raciocínio emergente



- Receita minimalista: modelo base + RLVR — **Sem SFT** (DeepSeek R1-Zero)
  - O modelo tende a gerar cadeias de raciocínio mais longas — CoT emergente
  - Reflexão e Backtracking.

# DeepSeek-R1

R1-Zero tem problemas — DeepSeek-R1 faz um pós-treino mais completo

- **Cold Start:** SFT com poucos milhares de CoTs longos e curados
- **RL** com recompensas verificáveis (+ consistência de língua)
- Novo **SFT** com dados gerados/filtrados + dados gerais
- **RL** final (incluindo preferências, à la RLHF)
  - **Destilação:** SFT de modelos pequenos sobre traços do R1 transfere boa parte do raciocínio
  - **Ciclo fechado:** na Aula 18, CoT era um truque de *prompt*; agora é um comportamento treinado por RL

# RLVR

## Outros casos de sucesso

---

 **KIMI K1.5:**  
**SCALING REINFORCEMENT LEARNING WITH LLMs**

---

TECHNICAL REPORT OF KIMI K1.5

**Kimi Team**



2025-05-15

---

### **Qwen3 Technical Report**

**Qwen Team**


 <https://huggingface.co/Qwen>  
 <https://modelscope.cn/organization/qwen>  
 <https://github.com/QwenLM/Qwen3>

**Abstract**

Agentes

# LLMs como Agentes

- **RLVR (R1):** *horizonte 1*. Uma trajetória  $\rightarrow$  CoT  $\rightarrow$  recompensa verificável *no final*, sem feedback do ambiente.
- **Agente:** *horizonte*  $> 1$ . O modelo emite uma ação, o ambiente responde com uma observação, e o ciclo se repete.
- Mesma maquinaria de RL: agora a "sequência" inclui **chamadas de ferramenta** e respostas do ambiente.



# O que é um agente

- Um LLM que interage com um **ambiente externo** ao longo de **múltiplos passos** para cumprir uma tarefa.
- Ciclo: *perceber* (observação) → *decidir* (política) → *agir* (ação/ferramenta) → *observar* o resultado → repetir.
- Ambientes típicos: busca/web, navegador, repositório de código, sistema operacional.
- A ação não é apenas "texto": inclui **chamadas de ferramenta** (function calling), cujo resultado vira a próxima observação.

# Anatomia de um Agente

- **Política** — o próprio LLM.
- **Ações** — ferramentas / function calling (busca, executar código, navegar).
- **Percepção** — transformar a saída do ambiente em observação (parsing, compressão).
- **Memória** — porque *contexto*  $\neq$  *estado*; o que reter entre turnos.
- **Planejamento** — decompor a tarefa em sub-objetivos.

# Agência

Dois caminhos

## **(A) Scaffolding** (*sem treino*)

- Orquestrar um LLM congelado: ReAct, Reflexion.
- "Agência" mora no prompt + harness.
- Computação em **tempo de inferência**.

## **(B) Agentic RL** (*treino*)


- Estender RLVR a *múltiplos turnos*.
- "Agência" **amortizada nos pesos**
- Treinar a política, não só usá-la.

# Comentários Finais

*“The biggest lesson that can be read from 70 years of AI research is that general methods that leverage computation are ultimately the most effective, and by a large margin.”*

Richard Sutton, The Bitter Lesson (2019)

# The Bitter Lesson



- Algoritmos que escalam → Poder preditivo
- Perdemos a capacidade de interpretar — Fazer ciência também envolve explicar e intervir.

# O que não cobrimos

- **Interpretabilidade:** Implantamos sistemas cujo interior não entendemos. Interp. mecanicista, features, SAEs, etc.
- **Eficiência/Hardware:** O que torna tudo possível: FlashAttention, quantização, MoE, destilação, KV-cache, decodificação especulativa.
- **Avaliação:** Como saber de verdade que o modelo é bom? Saturação de benchmarks, contaminação, Goodhart. Talvez o maior ponto cego do campo.
- **Teoria:** Por que ICL funciona? Por que SGD generaliza neste regime? O gap teoria-prática é, ele próprio, uma fronteira.

# Direções recentes

- **Modelos Fundacionais**
- **Computação em tempo de inferência**
- **Contextos Longos**
- **Multi-modalidade/World Models**
- **AI for Science**
- **The Data Wall**
- ...

# Direções recentes

- **Modelos Fundacionais**
- **Computação em tempo de inferência**
- **Contextos Longos**
- **Multi-modalidade/World Models**
- **AI for Science**
- **The Data Wall**
- ...

## Como seguir:

- Fundamentos são importantes: probabilidade, otimização, álgebra linear, ...
- Aprender a *ler artigos de forma crítica*
- **Aprender a aprender** — o campo vai continuar se reescrevendo de tempos em tempos.